Evolução da Educação Pública em Mato Grosso do Sul (2018–2026): Dados Abertos, Banco Relacional e Dashboard Interativo

Universidade Católica Dom Bosco, Campo Grande, Brazil

Enzo Pasini, Lucas Fiaes, Victor Hugo, Mike Weyller, Davi Busembai, Gustavo Kochi

Abstract

Este trabalho investiga se a educação pública de Mato Grosso do Sul está evoluindo, no contexto do Objetivo de Desenvolvimento Sustentável 4 (ODS 4), a partir dos dados abertos de matrículas por unidade escolar publicados pelo governo do estado. Desenvolvemos um sistema em Python que lê oito arquivos CSV anuais (2018 a 2026, sem 2025), representa municípios, escolas e registros anuais como objetos, remove escolas repetidas entre os anos com tabelas *hash* e grava a série histórica em um banco relacional SQLite, consultado por um *dashboard* Streamlit com filtros de município e ano. A carga foi validada com 32 testes automatizados e com consultas de consistência: 3.703 registros, 598 escolas e 79 municípios, sem nenhuma divergência entre o banco e os arquivos de origem. A busca por município e ano no *hash* foi cerca de 1.400 vezes mais rápida que a busca sequencial em lista. A análise mostrou que a taxa de aprovação da rede pública subiu de 81,3% em 2018 para 88,7% em 2023, mas também revelou problemas sérios nos dados: o abandono deixou de ser registrado a partir de 2020, e os anos de 2024 e 2026 não têm resultados finais. Por isso, definimos e documentamos quais anos são válidos para cada indicador.

Keywords: dados abertos, indicadores educacionais, taxa de aprovação, tabela hash, qualidade de dados

1. Introdução

O Objetivo de Desenvolvimento Sustentável 4 (ODS 4) da Agenda 2030 busca garantir uma educação inclusiva, equitativa e de qualidade para todos [5]. Para saber se um estado caminha nessa direção, é preciso acompanhar indicadores ao longo do tempo. Dois dos mais usados no Brasil são a taxa de aprovação e a taxa de abandono, que o INEP calcula a partir da situação final de cada aluno no ano letivo [4].

O governo de Mato Grosso do Sul publica, no seu Portal de Dados Abertos, um arquivo por ano com as matrículas e a situação final dos alunos de cada escola pública [2]. Esses dados são públicos, mas não estão prontos para análise: cada ano fica em um arquivo separado, não existe um código que identifique a escola, e os nomes dos municípios aparecem com acentuação diferente. Responder a uma pergunta simples, como "a aprovação melhorou no meu município?", exige juntar e limpar vários arquivos.

O problema tratado neste trabalho é, portanto, transformar esses arquivos em uma série histórica confiável e fácil de consultar, e usá-la para responder se a educação pública do estado está evoluindo. As principais contribuições são:

- um sistema que carrega os dados de 2018 a 2026 em um banco relacional, usando orientação a objetos e tabelas *hash* de forma explícita, com carga idempotente e validada;
- um *dashboard* interativo com filtros por município e por ano;
- uma análise da evolução das taxas de aprovação e de abandono no estado;
- um levantamento dos problemas de qualidade desses dados abertos, com regras documentadas sobre quais anos podem ser usados em cada indicador.

O restante do artigo está organizado assim: a Seção 2 apresenta os trabalhos relacionados; a Seção 3 descreve os dados, o sistema e as métricas; a Seção 4 mostra os resultados; a Seção 5 discute os resultados e as limitações; e a Seção 6 traz as conclusões.

2. Trabalhos Relacionados

O INEP define as taxas de rendimento escolar (aprovação, reprovação e abandono) a partir da situação final do aluno, e usa como denominador apenas os alunos que terminaram o ano com uma dessas três situações [4]. Este trabalho segue a mesma definição, o que permite comparar os resultados com os indicadores oficiais.

Email addresses: enzo.cpasini@gmail.com (Enzo Pasini), ra204359@ucdb.br (Lucas Fiaes), ra204470@ucdb.br (Victor Hugo), ra195996@ucdb.br (Mike Weyller), ra199969@ucdb.br (Davi Busembai), ra200043@ucdb.br (Gustavo Kochi)

Diferente de análises feitas com planilhas ou com bibliotecas que escondem o processamento, este trabalho constrói explicitamente cada etapa (leitura, normalização, estruturas em memória e banco relacional), o que permite verificar e testar cada uma delas separadamente.

3. Materiais e Métodos

3.1. Dataset

Os dados vêm do conjunto "Matrículas por Unidade Escolar" do Portal de Dados Abertos de Mato Grosso do Sul [2], acessado em outubro de 2026. São oito arquivos CSV, um por ano (2018 a 2024 e 2026; não há arquivo de 2025), todos com as mesmas colunas, codificados em UTF-8 e separados por vírgula. Cada linha representa uma escola em um ano. No total são 3.703 linhas (Tabela 1).

As colunas trazem o ano, o nome do município, o nome da escola e onze contagens de alunos: o total de matrículas (`MatriculasTotal`), dividido em matrícula inicial e matrícula após o censo, e as situações finais: transferidos, cancelados, falecidos, abandono, aprovados, reprovados, cursando e outras situações. Duas regras de consistência foram observadas e usadas como teste:

- `MatriculasTotal` = matrícula inicial + matrícula após o censo;
- `MatriculasTotal` = soma das oito situações finais.

Tabela 1: Número de escolas (linhas) e total de matrículas em cada arquivo anual. Não existe arquivo de 2025 na fonte.

Ano	Escolas	Matrículas
2018	485	326.367
2019	475	293.195
2020	441	242.028
2021	442	248.780
2022	472	247.646
2023	467	237.574
2024	461	220.926
2026	460	199.489
Total	3.703	—

Três características dos dados exigiram tratamento especial:

1. **Não há código da escola.** O conjunto não traz o código INEP, então a escola foi identificada pelo par (município, nome da escola).
2. **A acentuação é inconsistente.** Alguns municípios aparecem com acento ("Água Clara") e outros sem ("Anastacio", "Camapua"), então o nome não pode ser usado como chave sem tratamento.
3. **Algumas escolas não têm alunos com situação final.** Escolas como os Centros Estaduais de Educação de Jovens e Adultos (CEEJA) têm aprovados + reprovados + abandono = 0, porque todos os alunos estão em "outras situações". Isso causaria uma divisão por zero no cálculo das taxas.

3.2. Arquitetura do sistema

O sistema foi escrito em Python 3 [7] usando apenas a biblioteca padrão para a carga (módulos `csv`, `unicodedata` e `sqlite3`), sem bibliotecas de análise de dados, para que a leitura, as classes e as estruturas de dados ficassem visíveis no código. O banco é um arquivo SQLite [3] e a interface usa o Streamlit [6]. A Figura 1 mostra o fluxo dos dados.

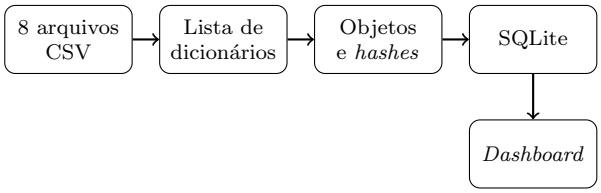


Figura 1: Fluxo dos dados: os CSVs são lidos como uma lista de dicionários, transformados em objetos ligados por tabelas *hash*, gravados no SQLite e consultados pelo *dashboard*.

Leitura e normalização. Cada arquivo é lido com `csv.DictReader`, que transforma cada linha em um dicionário (nome da coluna → valor). Para que o mesmo município ou escola tenha sempre a mesma chave, todos os nomes passam por uma regra fixa de normalização: os acentos são removidos (decomposição Unicode NFD e descarte das marcas de acento), o texto é convertido para maiúsculas e os espaços repetidos são retirados. O nome original também é guardado, para ser exibido. Preferimos uma regra fixa a uma comparação por similaridade de nomes, porque a comparação aproximada poderia juntar escolas diferentes com nomes parecidos.

Orientação a objetos. O domínio foi modelado com três classes. `Municipio` guarda o nome original, o nome normalizado e a lista das suas escolas. `Escola` guarda os nomes, uma referência ao seu município e a lista dos seus registros. `RegistroAnual` guarda o ano, as onze contagens convertidas para inteiro e uma referência à sua escola. As referências são bidirecionais: a partir de um município chega-se às escolas e aos registros, e a partir de um registro chega-se à escola e ao município. Uma quarta classe, `Totais`, soma as contagens de um grupo de registros e calcula as taxas.

Tabelas *hash*. Como a mesma escola aparece em vários anos, foi usado um dicionário Python (uma tabela *hash*) com a chave (município normalizado, escola normalizada) para garantir que cada escola seja criada uma única vez (Algoritmo 1). Um segundo *hash*, com chave (município, ano), guarda os totais já somados para responder aos filtros. Em uma tabela *hash*, a busca por chave tem custo médio $O(1)$, enquanto a busca em uma lista exige percorrer os elementos, com custo $O(n)$ [1].

Algoritmo 1 Montagem dos *hashes* sem escolas repetidas

Entrada: lista de linhas de todos os anos
Saída: *hashes municipios* e *escolas*

```
for cada linha do
    m ← normalizar(município da linha)
    e ← normalizar(escola da linha)
    if m ∉ municipios then
        municipios[m] ← novo Municipio
    if (m, e) ∉ escolas then
        escolas[(m, e)] ← nova Escola
        ligar a escola ao município m
    criar RegistroAnual e ligá-lo a escolas[(m, e)]
```

Banco relacional. O esquema tem três tabelas:

- `municipio`(id, nome, nome_normalizado UNIQUE);
- `escola`(id, nome, nome_normalizado, municipio_id FK), com UNIQUE(municipio_id, nome_normalizado);
- `registro_anual`(id, escola_id FK, ano e as onze contagens), com UNIQUE(escola_id, ano).

Os municípios são inseridos primeiro, depois as escolas e por último os registros, respeitando as chaves estrangeiras. Os identificadores gerados pelo SQLite são guardados em *hashes* auxiliares (por exemplo, nome normalizado → id), que fazem a ponte entre os objetos em memória e as chaves estrangeiras do banco. Todas as inserções usam `INSERT OR IGNORE`: junto com as restrições UNIQUE, isso torna a carga idempotente, ou seja, executá-la duas vezes não duplica nenhum dado.

Dashboard. A interface tem um filtro de município (com a opção "Todo o MS"), um filtro de intervalo de anos, cartões que comparam a taxa do último ano válido com a de 2018, gráficos de linha da evolução e uma tabela com os valores.

3.3. Métricas

Seguindo o padrão do INEP [4], as taxas usam como base apenas os alunos com situação final:

$$\begin{aligned} \text{base} &= \text{Aprovados} + \text{Reprovados} + \text{Abandono} \\ \text{taxa de aprovação} &= \text{Aprovados}/\text{base} \times 100 \\ \text{taxa de reprovação} &= \text{Reprovados}/\text{base} \times 100 \\ \text{taxa de abandono} &= \text{Abandono}/\text{base} \times 100 \end{aligned}$$

Ao agrupar escolas (por município ou pelo estado), as contagens são somadas primeiro e a divisão é feita uma única vez. Não se calcula a média das taxas das escolas, porque isso daria o mesmo peso a uma escola com 50 alunos e a uma com 2.000. Quando a base é zero, a taxa fica indefinida (`None` em Python e `NULL` no SQL, usando `NULLIF`), em vez de causar erro ou aparecer como 0%.

3.4. Setup do Experimento

A avaliação foi feita em três partes:

1. **Corretude da carga:** 32 testes automatizados (módulo `unittest`) cobrem leitura, normalização, classes, *hashes* e banco. Além disso, consultas SQL de validação comparam a contagem de registros por ano no banco com a dos arquivos CSV e procuram registros que violem as duas regras de soma. Essas consultas retornam apenas as linhas com erro, de modo que zero linhas significa que tudo está correto.
2. **Desempenho das estruturas:** a busca dos totais de um município em um ano (Campo Grande, 2018) foi repetida 1.000 vezes de duas formas: percorrendo a lista com os 3.703 registros e consultando o *hash* (município, ano). Foi medido o tempo médio por busca.
3. **Análise dos indicadores:** as taxas do estado e de cada município foram calculadas por consultas SQL e conferidas com os valores calculados em memória pela classe `Totais`. Antes da análise, verificamos ano a ano quantos alunos estavam em cada situação final, para decidir em quais anos cada taxa é confiável.

Os experimentos foram executados com Python 3.14 e Streamlit 1.66.1 em um computador pessoal com Windows 10.

4. Resultados

4.1. Carga e validação

A carga resultou em 79 municípios, 598 escolas distintas e 3.703 registros anuais. A normalização não mudou o número de municípios (79 antes e depois), mas protege a chave contra variações de grafia. Já entre as escolas, ela reduziu o total de 599 para 598, ao juntar um caso em que o mesmo nome aparecia como "MÜLLER" e "MULLER". Nenhuma escola apareceu duas vezes no mesmo ano.

Os 32 testes passaram. A contagem de registros por ano no banco foi igual à dos CSVs em todos os oito anos, e as duas regras de soma não tiveram nenhuma violação. Ao executar a carga uma segunda vez, os totais continuaram em 79, 598 e 3.703, o que confirma que a carga é idempotente.

4.2. Desempenho: lista versus hash

A Tabela 2 mostra o resultado da comparação. A busca no *hash* foi cerca de 1.400 vezes mais rápida, e as duas formas retornaram o mesmo resultado. Em execuções diferentes a razão variou entre aproximadamente 1.400 e 1.600 vezes, mas a diferença de ordem de grandeza se manteve.

Tabela 2: Tempo médio de 1.000 buscas dos totais de Campo Grande em 2018, sobre 3.703 registros.

Estrutura	Complexidade	Tempo por busca
Lista	$O(n)$	149,9 μs
Hash (município, ano)	$O(1)$	0,107 μs

4.3. Qualidade dos dados por ano

A verificação das situações finais revelou que nem todos os anos podem ser usados para todas as taxas:

- **Abandono:** 10.490 alunos em 2018 e apenas 158 em 2019 (queda de 98,5% em um ano, enquanto as matrículas caíram cerca de 10%). De 2020 a 2026, o abandono é zero em todas as escolas.
- **2024:** 184.949 dos 220.926 alunos (cerca de 84%) estão como "cursando", só 3.484 aparecem como aprovados, e 379 das 461 escolas têm base zero.
- **2026:** o ano letivo ainda não terminou, então não há aprovados, reprovados nem abandono, e todas as 460 escolas têm base zero.

Com isso, definimos as regras da Tabela 3. Elas ficam na camada de dados (constantes no módulo do banco), e não só no *dashboard*, para que qualquer consulta ao banco siga a mesma regra. Fora dos anos válidos, a taxa é exibida como "não disponível", nunca como 0%.

Tabela 3: Anos usados em cada indicador e motivo.

Indicador	Anos	Motivo
Matrículas	2018–2026	Preenchidas em todos os anos, sem erros
Aprovação e reprovação	2018–2023	2024 e 2026 sem resultados finais
Abandono	2018	Não registrado a partir de 2019/2020

4.4. Evolução dos indicadores no estado

A Tabela 4 e a Figura 2 mostram as taxas da rede pública. A aprovação subiu de 81,3% em 2018 para 88,7% em 2023 (+7,3 pontos percentuais), e a reprovação caiu de 14,6% para 11,3%. A maior parte da subida aconteceu entre 2018 e 2020; de 2020 a 2023 a aprovação ficou estável, entre 88,0% e 89,4%. A taxa de abandono só pode ser calculada para 2018: 4,0% no estado e 5,4% em Campo Grande. O total de matrículas caiu de 326.367 em 2018 para 237.574 em 2023 (-27,2%) e para 199.489 em 2026.

Tabela 4: Taxas da rede pública de Mato Grosso do Sul por ano (%). "n/d" = não disponível, conforme a Tabela 3.

Ano	Aprovação	Reprovação	Abandono
2018	81,3	14,6	4,0
2019	86,7	13,2	n/d
2020	89,4	10,6	n/d
2021	88,4	11,6	n/d
2022	88,0	12,0	n/d
2023	88,7	11,3	n/d

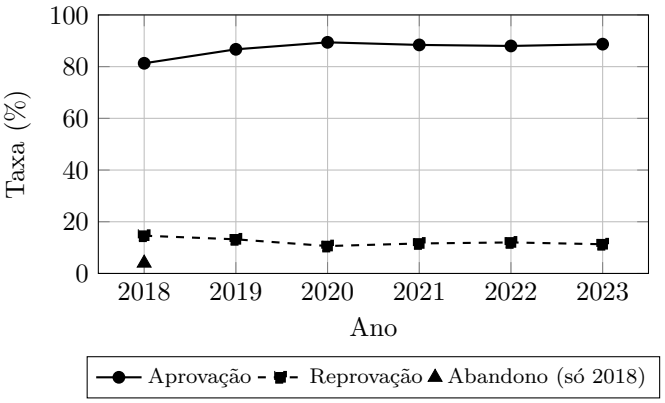


Figura 2: Evolução das taxas de aprovação e reprovação da rede pública de 2018 a 2023. O abandono só é confiável em 2018. Anos de 2024 e 2026 não aparecem porque não têm resultados finais.

5. Discussão

A aprovação melhorou, mas menos do que parece. A subida de 7,3 pontos entre 2018 e 2023 precisa ser lida com cuidado. Em 2018 o abandono fazia parte da base; a partir de 2020 ele passou a ser zero, então a base passou a ter só aprovados e reprovados. Isso aumenta a taxa de aprovação mesmo que nada tenha mudado nas escolas. Se calcularmos a aprovação de 2018 sem o abandono na base, como nos anos seguintes, ela seria 81,3 / (81,3 + 14,6) $\approx$ 84,8%. Comparada com essa referência, a melhora até 2023 é de cerca de 3,9 pontos, e não de 7,3. A queda da reprovação (de 14,6% para 11,3%) não depende do abandono, e por isso é a evidência mais segura de melhora. Também é importante notar que a maior mudança ocorreu em 2020 e 2021, anos de ensino remoto na pandemia, quando as regras de avaliação e aprovação mudaram em muitas redes; os dados não permitem separar esse efeito de uma melhora real.

O abandono não pode ser acompanhado. A queda de 10.490 para 158 alunos em um ano, seguida de zeros em todas as escolas, é muito mais compatível com uma mudança no registro do que com o fim real do abandono escolar. Por isso a taxa de abandono foi limitada a 2018, e o principal indicador do ODS 4 ligado à permanência não pode ser avaliado com este conjunto de dados. Mostrar 0% nesses anos seria uma informação falsa; por isso o sistema mostra "não disponível".

Queda das matrículas. A rede pública perdeu 27% das matrículas entre 2018 e 2023. Com os dados disponíveis não é possível saber a causa (por exemplo, municipalização de etapas de ensino, migração para outras

redes ou queda da população em idade escolar), o que fica como pergunta para trabalhos futuros.

Decisões de projeto. A falta de código da escola obrigou a identificar escolas por nome, o que funciona porque a normalização é feita com uma regra fixa. A desvantagem é que uma escola que mudou de nome entre os anos é tratada como duas escolas diferentes; a vantagem é que duas escolas diferentes com nomes parecidos nunca são juntadas por engano. A comparação entre lista e *hash* confirmou na prática a diferença entre $O(n)$ e $O(1)$: com apenas 3.703 registros a diferença já passa de mil vezes, e ela cresceria com mais dados. Colocar as regras de anos válidos na camada de dados, e não na interface, garante que o *dashboard* e qualquer outra consulta mostrem os mesmos números.

Limitações. Os dados não incluem 2025, não trazem a etapa de ensino (fundamental ou médio), e as taxas a partir de 2020 não incluem o abandono. Não foi feito teste estatístico sobre a tendência, porque há apenas seis anos válidos para a aprovação e um para o abandono.

6. Conclusão

Este trabalho transformou oito arquivos de dados abertos em uma série histórica validada, armazenada em um banco relacional e consultada por um *dashboard* com filtros por município e ano. O uso explícito de classes, de tabelas *hash* e de restrições do banco permitiu remover escolas repetidas, fazer uma carga idempotente e conferir cada etapa com testes, sem nenhuma divergência em relação aos arquivos de origem. A busca por *hash* foi cerca de 1.400 vezes mais rápida que a busca em lista.

Sobre a pergunta principal, os dados indicam uma melhora moderada: a reprovação caiu de 14,6% para 11,3% entre 2018 e 2023, e a aprovação subiu, embora parte dessa subida venha da mudança no registro do abandono. O resultado mais importante, porém, é sobre os próprios dados: o abandono deixou de ser registrado e os anos mais recentes estão incompletos, o que hoje impede acompanhar parte das metas do ODS 4 com esse conjunto de dados.

Como trabalhos futuros, sugerimos incluir o código INEP das escolas para identificá-las sem depender do nome, cruzar estes dados com o Censo Escolar para recuperar o abandono, separar os indicadores por etapa de ensino, e atualizar a carga quando os resultados de 2024 a 2026 forem publicados.

Referências

[1] Cormen, T. H., Leiserson, C. E., Rivest, R. L., Stein, C., 2009. Introduction to Algorithms, 3rd Edition. MIT Press, Cambridge, MA.

[2] Governo do Estado de Mato Grosso do Sul, 2026. Matrículas por unidade escolar. Portal de Dados Abertos de Mato Grosso do Sul, acesso em: 28 out. 2026.
URL `https://www.dados.ms.gov.br/dataset/matriculas-por-unidade-escolar`

[3] Hipp, D. R., 2026. Sqlite. Acesso em: 28 out. 2026.
URL `https://www.sqlite.org`

[4] Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP), 2026. Taxas de rendimento escolar. Acesso em: 28 out. 2026.
URL `https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/indicadores-educacionais/taxas-de-rendimento-escolar`

[5] Nações Unidas Brasil, 2015. Objetivo de desenvolvimento sustentável 4: Educação de qualidade. Acesso em: 28 out. 2026.
URL `https://brasil.un.org/pt-br/sdgs/4`

[6] Streamlit Inc., 2026. Streamlit: A faster way to build and share data apps. Versão 1.66.1. Acesso em: 28 out. 2026.
URL `https://streamlit.io`

[7] Van Rossum, G., Drake, F. L., 2009. Python 3 Reference Manual. CreateSpace, Scotts Valley, CA.